DOSSIER D’ANALYSE

PRÉDICTION DE LA NOTE À PARTIR DES TRACES SUR ARCHE

PAR KHADY DIAGNE
M2 SCIENCE DES DONNEES (SDD)
IDMC - UNIVERSITE DE LORRAINE 2025-2026

Table des matières

I. Contexte et objectif du projet 0

II. Chargement et prétraitement des données 0

1. Sources de données 0

2. Définition des variables principales des logs 0

3. Chargement et validation des données 1

4. Prétraitement du fichier des notes 1

5. Prétraitement du fichier des logs 1

6. Mise en cohérence entre les deux sources 2

7. Audit de qualité des données 2

8. Bilan du chargement et du prétraitement 3

III. Analyse exploratoire des données (EDA) 3

1. Distribution des notes 3

2. Distribution du nombre d'actions 4

3. Diversité des contextes consultés 5

4. Étudiants sans activité enregistrée 5

5. Relation entre activité brute et note 6

6. Répartition des catégories d'événements 6

7. Analyse des événements les plus fréquents 7

IV. Construction des variables explicatives 8

1. Variables structurelles 8

2. Variable temporelle 8

3. Variables comportementales 9

4. Variable liée aux composants 9

5. Dataset final 10

6. Analyse des corrélations entre variables construites 10

V. Modèle imposé : Régression multiple 11

1. Formalisation du problème 11

2. Modèle de régression multiple 12

3. Sélection des variables 12
4. Formulation du modèle 13
5. Interprétation statistique 14
6. Métriques d'évaluation 14
7. Évaluation prédictive 15
8. Multicolinéarité 16
9. Limites du modèle 16
10. Conclusion 17
VI. Modèle comparatif : arbre de décision régressif 17
1. Principe du modèle 17
2. Variables utilisées 18
3. Résultats obtenus 18
4. Analyse graphique 18
5. Interprétation 19
6. Limites du modèle 19
7. Conclusion 19
VII. Analyse comparative des modèles 20
1. Qualité des prédictions 20
2. Analyse des résidus 20
3. Capacité explicative 21
4. Comparaison des performances 21
5. Interprétation 22
6. Conclusion 22
VIII. Interface de prédiction 23
1. Positionnement dans le projet 23
2. Objectif de l'interface 23
3. Cohérence avec la modélisation 23
4. Logique de prédiction 23
5. Restitution des résultats 24

6. Exemple d'interprétation d'un profil 24
7. Analyse comparative des modèles sur cet exemple 26
8. Limites 27
9. Intérêt pédagogique 27
10. Conclusion de l'interface 28
Conclusion générale 28

GITHUB: https://github.com/ladijadi/Projet_Arche

I. Contexte et objectif du projet

Dans le cadre de ce projet, l'objectif est de **prédire la note finale d'un étudiant (sur 20)** à partir de ses traces d'activité sur la plateforme pédagogique ARCHE.

Ces traces correspondent aux interactions des étudiants avec différents types de ressources (fichiers, forums, contenus, etc.). L'enjeu est de comprendre les comportements d'apprentissage et construire un modèle prédictif exploitable.

II. Chargement et prétraitement des données

1. Sources de données

Le projet repose sur deux fichiers CSV complémentaires.

Le premier fichier contient les traces d'activité enregistrées sur la plateforme ARCHE. Chaque ligne correspond à une action réalisée par un utilisateur et comporte notamment un identifiant anonyme *(pseudo),* un horodatage *(heure),* un contexte pédagogique *(contexte),* un type de composant *(composant)* et un événement détaillé *(evenement).*

Le second fichier contient les notes finales des étudiants. Il associe à chaque identifiant pseudo une valeur numérique note, qui constitue la variable cible du problème de prédiction.

L'analyse repose donc sur la mise en relation de deux niveaux d'information différents : d'un côté des données événementielles brutes, très détaillées, et de l'autre une mesure synthétique de performance académique.

2. Définition des variables principales des logs

Parmi les variables du **fichier de logs**, deux champs jouent un rôle central dans l'analyse : *composant et contexte*. Le champ composant correspond au type général d'activité réalisée sur la plateforme. Il permet de distinguer, par exemple, les actions liées à un fichier, à un forum, à un test ou à un contenu pédagogique. Cette variable renseigne donc sur la nature globale de l'interaction : lecture, consultation, évaluation ou participation.

Le champ *contexte* désigne quant à lui la ressource précise sur laquelle porte l'action. Il permet de distinguer des objets pédagogiques distincts, même lorsqu'ils appartiennent au même type de *composant*. Ainsi, plusieurs contextes différents peuvent être rattachés à un même composant.

L'utilisation conjointe de ces deux variables permet de décrire deux dimensions complémentaires du comportement étudiant : le type d'activité réalisé, via *composant*, et la diversité des ressources effectivement mobilisées, via *contexte.* Cette distinction est importante, car elle évite de réduire l'analyse à une simple mesure de volume d'activité.

3. Chargement et validation des données

Le chargement des données a été réalisé à l'aide d'un module dédié, dont le rôle est de sécuriser l'entrée des fichiers dans le pipeline d'analyse.

Dans un premier temps, l'existence physique des deux fichiers est vérifiée. Une tentative de lecture est ensuite effectuée pour chacun d'eux. Plusieurs types d'erreurs sont pris en compte, notamment l'absence du fichier, un fichier vide, une erreur de parsing ou encore un problème d'accès au fichier.

Une fois les fichiers chargés, la structure des tables est contrôlée. Pour le fichier des logs, les colonnes attendues sont ***heure, pseudo, contexte, composant et evenement***. Pour le fichier des notes, les colonnes attendues sont ***pseudo*** et ***note***. Ce contrôle permet de garantir que les traitements ultérieurs reposent sur une structure cohérente.

Cette étape de validation est indispensable, car elle permet de détecter très tôt les anomalies de format, avant toute transformation ou modélisation.

4. Prétraitement du fichier des notes

Le prétraitement du fichier des notes vise à sécuriser la variable cible.

Le champ *pseudo* est d'abord converti en numérique afin de déceler les identifiants invalides. Les lignes pour lesquelles cette conversion échoue sont supprimées. Les identifiants conservés sont ensuite convertis en entiers. Les doublons exacts sont ensuite éliminés, afin d'éviter que certaines observations soient comptées plusieurs fois.

La variable ***note*** est également convertie en numérique. Les valeurs inexploitables sont supprimées. À l'issue de cette étape, le fichier des notes contient uniquement des identifiants valides et une variable cible numérique exploitable.

5. Prétraitement du fichier des logs

Le prétraitement des ***logs*** est plus important, car ce fichier constitue la source principale des variables explicatives. Le champ pseudo est converti en numérique, puis les identifiants

invalides sont supprimés. Le champ heure est transformé en format date-heure afin de permettre les traitements temporels ultérieurs.

Les colonnes textuelles ***contexte, composant et evenement*** sont ensuite normalisées. Cette normalisation comprend la suppression des espaces superflus, le passage en minuscule et la suppression des accents. Elle permet d'éviter qu'une même information soit artificiellement représentée par plusieurs modalités différentes en raison de simples variations d'écriture.

Les lignes ne contenant aucune information exploitable sur ces dimensions textuelles sont supprimées. Les doublons exacts sont également retirés.

Enfin, une variable synthétique ***categorie_evenement*** est construite à partir de la variable brute ***evenement.*** Ce regroupement permet de ramener les événements détaillés à quelques grandes catégories comportementales, telles que ***test, consultation, interaction, visite_guidee, navigation ou autre***. Cette étape simplifie l'information brute et prépare la construction des variables comportementales.

6. Mise en cohérence entre les deux sources

Une fois les deux fichiers nettoyés, une étape de **cohérence** est réalisée entre les logs et les notes. Tous les utilisateurs présents dans les logs ne correspondent pas nécessairement à des étudiants évalués. Inversement, certains étudiants présents dans le fichier des notes peuvent ne présenter aucune activité enregistrée sur ARCHE. Afin de construire un jeu supervisé cohérent, les logs sont filtrés pour ne conserver que les étudiants présents dans le fichier des notes.

Cette décision permet d'aligner les variables explicatives et la variable cible au niveau des mêmes individus. Elle conduit également à identifier explicitement les étudiants présents dans les notes mais absents des logs, ce qui constitue une limite importante du signal observé.

7. Audit de qualité des données

Un audit complémentaire est réalisé après prétraitement afin de vérifier la **qualité structurelle des données**. Cet audit porte notamment sur la présence éventuelle de valeurs manquantes résiduelles, sur la validité de la variable note, sur la cohérence des identifiants pseudo et sur la plage temporelle couverte par les logs.

L'objectif de cet audit n'est pas de prouver l'absence totale d'erreurs métier, mais de vérifier que le jeu de données nettoyé est suffisamment cohérent pour permettre une analyse statistique et une modélisation fiable.

8. Bilan du chargement et du prétraitement

Les opérations de chargement et de prétraitement permettent de transformer deux fichiers bruts en un socle de données cohérent, exploitable et aligné avec l'objectif du projet.
Cette phase joue un rôle essentiel, car elle conditionne la qualité des analyses suivantes. Elle permet non seulement de corriger les anomalies techniques les plus courantes, mais aussi de préparer une représentation plus structurée du comportement étudiant, qui sera ensuite enrichie par le feature engineering.

III. Analyse exploratoire des données (EDA)

1. Distribution des notes

L'étude de la distribution des notes montre que les résultats sont relativement concentrés. Les valeurs observées s'étendent approximativement de 7,8 à 12,3, avec une moyenne proche de 10 et un écart-type limité. La majorité des étudiants se situe donc dans une zone intermédiaire, sans présence de valeurs extrêmes particulièrement marquées. Cette faible dispersion constitue un élément important pour l'interprétation des performances des modèles. En effet, lorsque la variable cible varie peu, la capacité des modèles à discriminer fortement les profils étudiants devient mécaniquement plus limitée. Cette caractéristique du jeu de données contribue à expliquer le niveau modéré des coefficients de détermination obtenus lors de la modélisation.

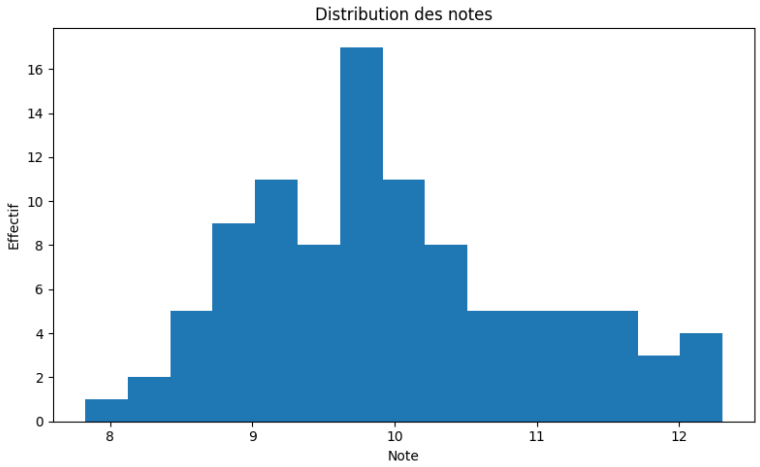

Figure 1 : Distribution des notes des étudiants

2. Distribution du nombre d'actions

La distribution du nombre d'actions par étudiant est fortement asymétrique à droite. La majorité des étudiants présente un volume d'activité faible à modéré, tandis qu'un petit nombre d'individus se distingue par une activité très élevée. Le cas le plus extrême atteint un nombre d'actions nettement supérieur au reste de la population.

Cette configuration met en évidence une forte hétérogénéité des usages de la plateforme. Tous les étudiants n'utilisent pas ARCHE avec la même intensité, ce qui suggère que l'activité observée ne renvoie pas à un comportement homogène. Cette asymétrie invite également à la prudence : un volume d'actions important ne doit pas être interprété automatiquement comme un signe de meilleure performance.

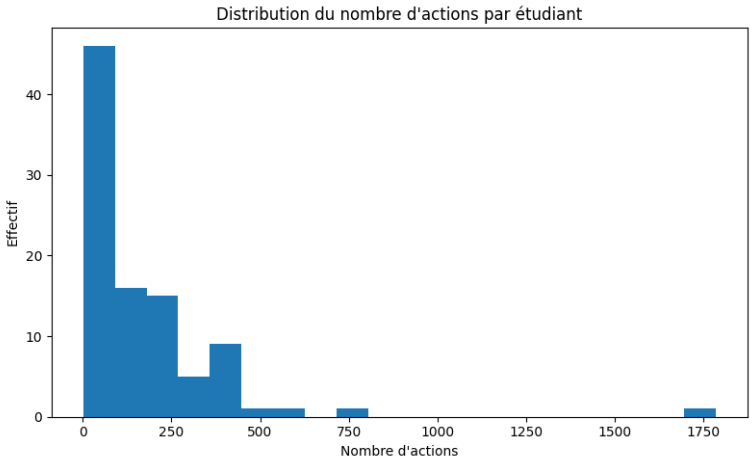

Figure 2 : Distribution du nombre d'actions par étudiant sur la plateforme ARCHE

3. Diversité des contextes consultés

L'analyse du nombre de contextes distincts consultés montre également une dispersion importante entre les étudiants. Certains profils explorent un nombre très limité de contextes, tandis que d'autres mobilisent un éventail beaucoup plus large de ressources.

Cette variable est particulièrement intéressante, car elle ne mesure pas simplement le volume d'activité, mais la diversité des espaces pédagogiques consultés. Elle permet ainsi de distinguer des comportements plus variés de comportements plus restreints. Dans l'analyse de corrélation, cette variable apparaît comme la plus liée à la note parmi les indicateurs principaux, ce qui suggère que la diversité d'usage de la plateforme joue un rôle plus structurant que le seul nombre d'actions.

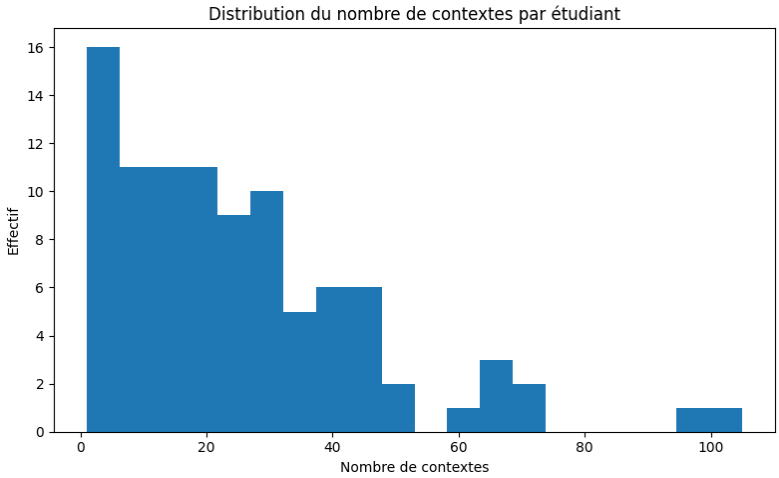

Figure 3 : Distribution du nombre de contextes distincts consultés par étudiant

4. Étudiants sans activité enregistrée

L'exploration met en évidence la présence de quatre étudiants figurant dans le fichier des notes mais absents des logs d'activité. Ces cas sont importants sur le plan analytique, car ils révèlent une limite structurelle du signal disponible.

Ils montrent que la performance académique ne dépend pas exclusivement des interactions enregistrées sur la plateforme. Une partie du travail étudiant peut avoir lieu hors d'ARCHE, ou ne pas être capturée par les logs disponibles. Cette observation justifie une lecture prudente des modèles : les traces comportementales constituent un indicateur partiel, et non une représentation exhaustive de l'engagement.

5. Relation entre activité brute et note

La corrélation entre le nombre total d'actions et la note est positive, mais d'intensité modérée, avec une valeur d'environ 0,35. Cette relation suggère qu'une activité plus importante peut être associée à de meilleures performances, sans toutefois constituer un facteur explicatif suffisant à elle seule.

Autrement dit, la quantité d'activité ne permet pas de rendre compte de façon satisfaisante de la réussite académique. Cette observation conduit à privilégier une lecture plus qualitative des comportements : la nature des actions réalisées et la diversité des ressources consultées paraissent plus informatives que le seul volume de clics.

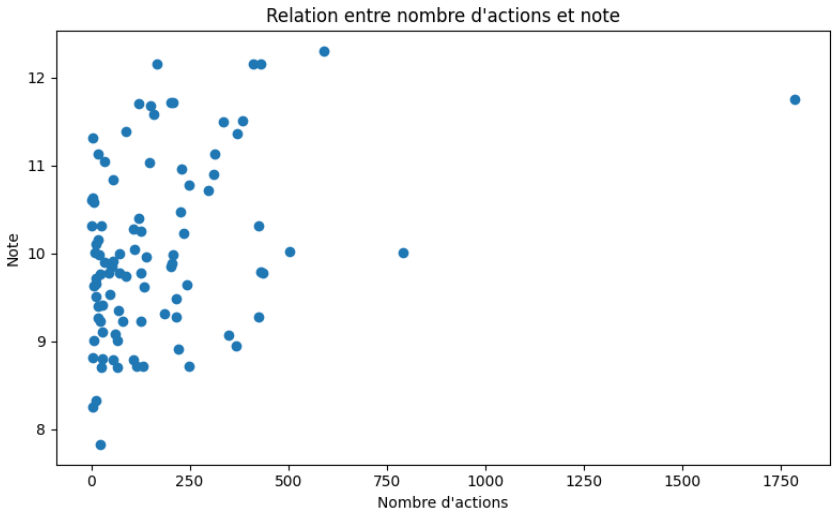

Figure 4 : Corrélation entre Nombre total d'actions et note

6. Répartition des catégories d'événements

La répartition des catégories d'événements met en évidence une domination nette des activités de type test et consultation. Les autres catégories, telles que navigation, visite_guidée ou interaction, occupent une place beaucoup plus marginale.

Cette structure indique que l'usage de la plateforme est principalement orienté vers deux fonctions : l'accès aux contenus et la réalisation d'activités d'évaluation. En revanche, les dimensions plus interactives apparaissent très peu représentées dans les données. Cela constitue une information importante pour l'interprétation des variables construites ensuite, notamment celles liées aux ratios comportementaux.

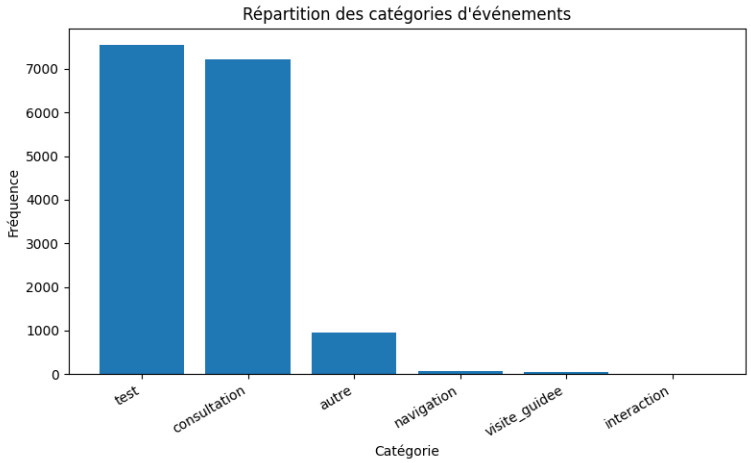

Figure 5 : Répartition des catégories d'événements observées dans les logs.

7. Analyse des événements les plus fréquents

L'examen des événements les plus fréquents confirme cette lecture générale. Les actions dominantes correspondent à la consultation de modules de cours, à la consultation de cours et à des activités liées aux tentatives de test.

Cette répartition suggère que la plateforme est avant tout utilisée comme support de consultation de ressources et de réalisation d'évaluations. L'usage observé semble donc davantage structuré autour de la lecture et du contrôle des acquis que d'une interaction riche avec différents types d'outils.

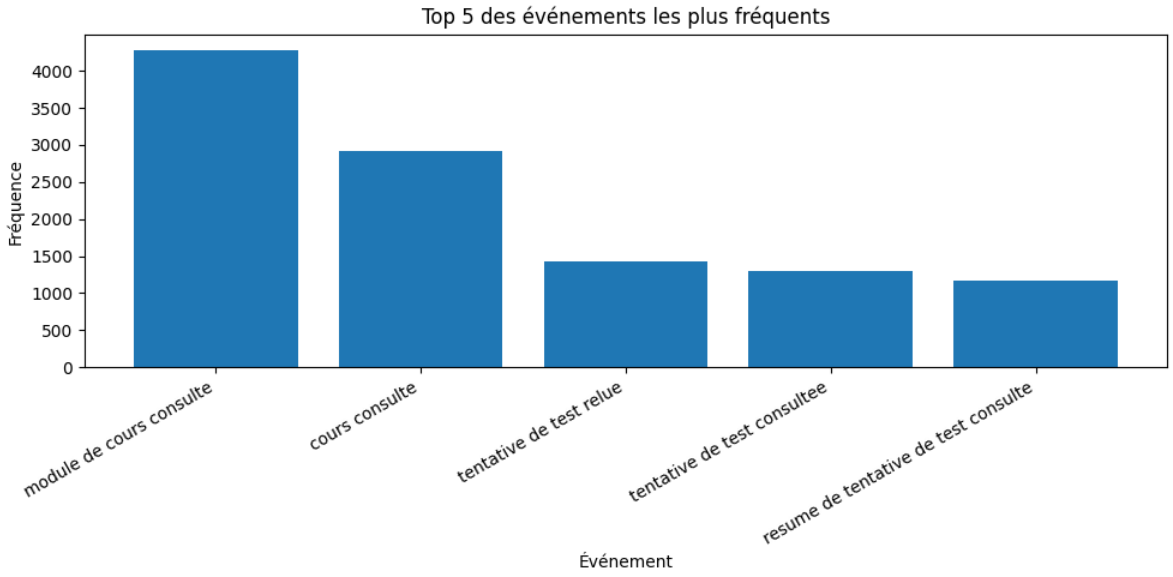

Figure 6 : Top 5 des événements les plus fréquents dans les traces

IV. Construction des variables explicatives

Le *feature engineering* constitue une étape déterminante du projet, car il permet de transformer des logs bruts, difficiles à exploiter directement, en indicateurs synthétiques décrivant le comportement de chaque étudiant. L'enjeu n'est pas seulement de compter les actions, mais de construire des variables capables de capturer différentes dimensions de l'engagement sur la plateforme.

1. Variables structurelles

Trois premières variables ont été construites pour caractériser l'usage global d'ARCHE :

- ***nb_contextes,*** qui mesure la diversité des ressources consultées

$$nb_contextes_i = |\{contexte_j\}|$$

- ***nb_actions,*** qui mesure le volume total d'activité ;

$$nb_actions_i = \sum_{j=1}^{N_i} 1$$

- ***nb_jours_actifs,*** qui mesure la régularité temporelle de l'usage.

$$nb_jours_actifs_i = |\{date(heure_j)\}|$$

Parmi ces variables, nb_contextes s'est révélée particulièrement informative dans l'analyse exploratoire, ce qui suggère que la diversité des ressources mobilisées est plus importante que le simple volume d'activité.

2. Variable temporelle

Une dimension temporelle a été introduite dans l'analyse à partir des écarts entre actions successives.

Une première variable, ***temps_moyen_action***, estime le temps moyen d'activité par action. Elle repose sur la conservation des seuls écarts strictement positifs et inférieurs à 300 secondes, afin d'approcher des séquences d'activité continues et d'éviter d'assimiler des interruptions longues à du temps de travail effectif.

$$\Delta tj = tj - tj - 1$$

$$temps_moyen_action_i = \frac{1}{K}\sum_{j=1}^{K} \Delta\, t_j$$

avec : $\Delta t_j < 300$ secondes

Une seconde variable, ***temps_moyen_jour_actif***, a été construite afin de mieux rendre compte de l'intensité quotidienne de l'activité. Elle correspond au temps moyen d'activité estimé par jour actif, calculé à partir des mêmes écarts temporels courts, mais en agrégeant d'abord l'activité au niveau de chaque journée avant de calculer une moyenne par étudiant.

L'introduction de ces deux indicateurs permet de distinguer deux lectures complémentaires du temps : une intensité moyenne rapportée au volume total d'actions, et une intensité moyenne rapportée aux jours effectivement actifs. Cette approche vise à enrichir l'analyse du comportement étudiant au-delà du seul volume d'activité.

3. Variables comportementales

Le regroupement des événements en grandes catégories a permis de construire plusieurs ratios :

- ratio_test
- ratio_interaction
- ratio_consultation
- engagement_actif

Ces indicateurs permettent de distinguer différentes formes d'usage de la plateforme comme un usage plus orienté vers l'évaluation ou plus interactif ou plus passif centré sur la consultation. L'indicateur ***engagement_actif*** a été conçu pour synthétiser la part des comportements considérés comme les plus impliquants sur le plan pédagogique.

$$engagement_actif_i = ratio_test_i + ratio_interaction_i$$

4. Variable liée aux composants

La variable ***ratio_fichier*** mesure la part des actions liées au composant fichier.

$$ratio_fichier_i = \frac{nb_actions_fichier_i}{nb_actions_i}$$

Elle permet de distinguer les étudiants dont l'activité est davantage centrée sur la consultation de documents de ceux qui mobilisent un ensemble plus varié de ressources et d'interactions.

Dans l'analyse exploratoire, cette variable est apparue négativement liée à la performance, ce qui suggère qu'un usage trop concentré sur ce type de ressource est moins favorable.

5. Dataset final

L'ensemble des variables a été fusionné avec le fichier des notes, de manière à obtenir un jeu de données final au niveau étudiant. Ce tableau constitue la base des analyses de corrélation, de la sélection des variables et des modèles prédictifs.

$$\textbf{Dataset final} = \{(\boldsymbol{x_i}, \boldsymbol{y_i})\}_{\boldsymbol{i=1}}^{\boldsymbol{n}}$$

où $x_i \in \mathbb{R}^p$= vecteur de variables explicatives et $y_i \in \mathbb{R}$= note

Logs bruts $\rightarrow$ Agrégation par étudiant $\rightarrow$ $X \in \mathbb{R}^{n \times p}$

6. Analyse des corrélations entre variables construites

L'analyse des corrélations entre les variables explicatives et la note permet d'identifier les signaux les plus informatifs.

La variable *nb_contextes* présente la corrélation positive la plus élevée avec la note (≈ 0,46), suivie par *nb_actions* (≈ 0,37). Ces résultats confirment que la diversité et le volume d'activité sont des indicateurs pertinents, bien que non suffisants.

La variable temporelle *temps_moyen_jour_actif* présente une corrélation positive modérée avec la note (≈ 0,29). Cela suggère qu'une intensité d'activité plus élevée par jour actif est associée à de meilleures performances, sans pour autant constituer un facteur déterminant.

En comparaison, *temps_moyen_action* présente une corrélation plus faible (≈ 0,09), indiquant que cette mesure est moins discriminante. Cela s'explique probablement par le fait qu'elle dilue l'information temporelle en la rapportant au nombre total d'actions, sans tenir compte de la structure journalière de l'activité.

Les variables comportementales, telles que *ratio_test* et *engagement_actif*, présentent également des corrélations positives modérées (≈ 0,27), tandis que *ratio_consultation* et *ratio_fichier* sont négativement corrélées à la note.

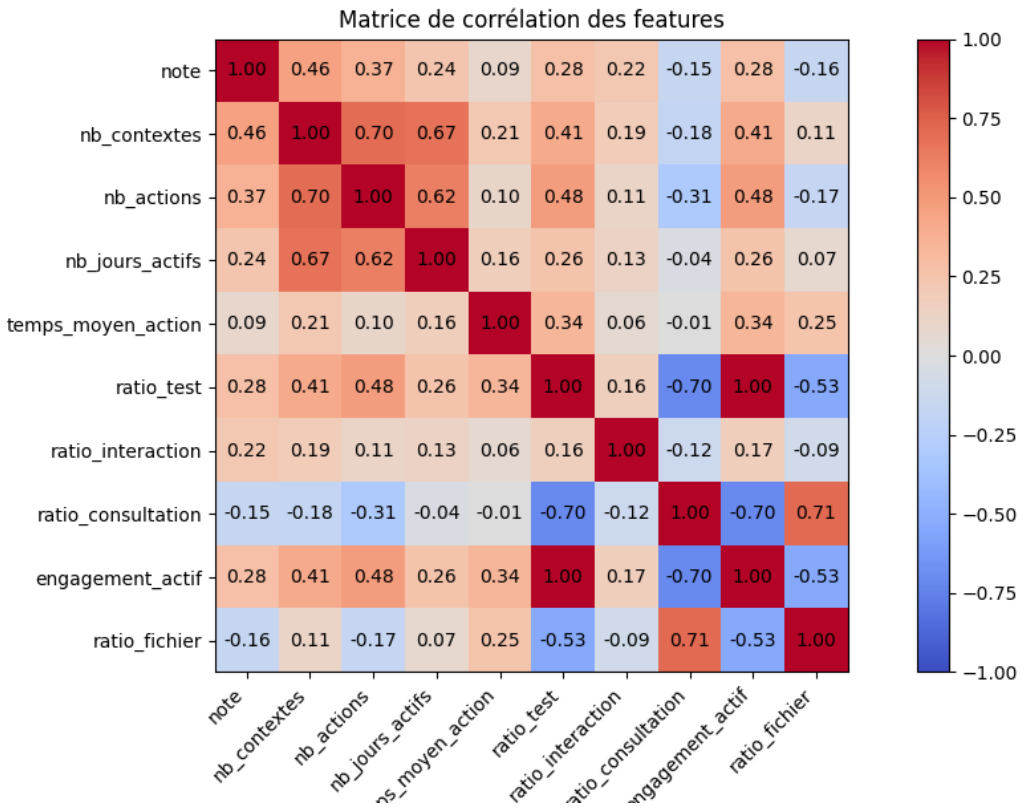

Figure 7 : Matrice de Corrélation des features

V. Modèle imposé : Régression multiple

Après la phase d'exploration et la construction des variables explicatives, une régression multiple a été mise en œuvre afin d'estimer la note à partir des indicateurs comportementaux construits.

1. Formalisation du problème

Le problème étudié est formulé comme un problème de régression supervisée.

On considère un ensemble de données :

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n}$$

où :

- $x_i \in \mathbb{R}^p$ Représente le vecteur des variables explicatives pour l'étudiant i
- $y_i \in \mathbb{R}$ Représente la note associée

Les variables explicatives sont construites à partir des logs bruts via une fonction de transformation :

$$x_i = f(\text{logs}_i)$$

Cette transformation permet de passer d'un espace événementiel (logs), non directement exploitable, à un espace vectoriel structuré, compatible avec les modèles de régression.

2. Modèle de régression multiple

Le modèle de régression linéaire multiple s'écrit :

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \varepsilon_i$$

où :

- β_0 est l'ordonnée à l'origine
- β_1, β_2 sont les coefficients associés aux variables explicatives
- ε_i représente le terme d'erreur

Les coefficients sont estimés par la méthode des moindres carrés ordinaires (OLS), qui consiste à minimiser la somme des erreurs quadratiques :

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

3. Sélection des variables

La modélisation a été précédée d'une sélection descendante (backward selection) fondée sur la significativité statistique des coefficients (p-values).

Le modèle initial incluait les variables suivantes :

- nb_contextes,
- ratio_test,
- ratio_interaction,
- temps_moyen_action,
- temps_moyen_jour_actif
- et ratio_fichier.

La procédure backward a conduit à supprimer successivement :

- temps_moyen_jour_actif,
- temps_moyen_action,
- ratio_test
- et ratio_interaction.

Et le modèle ne retient finalement que ***nb_contextes et ratio_fichier***.

```
SÉLECTION DESCENDANTE DES VARIABLES...
Suppression de temps_moyen_jour_actif (p-value = 0.8463)
Suppression de temps_moyen_action (p-value = 0.3615)
Suppression de ratio_test (p-value = 0.5611)
Suppression de ratio_interaction (p-value = 0.2046)

Variables retenues :
['nb_contextes', 'ratio_fichier']

Résumé du modèle final de sélection :
                            OLS Regression Results
==============================================================================
Dep. Variable:                   note   R-squared:                       0.252
Model:                            OLS   Adj. R-squared:                  0.237
Method:                 Least Squares   F-statistic:                     16.19
Date:                Sun, 12 Apr 2026   Prob (F-statistic):           8.71e-07
Time:                        12:55:59   Log-Likelihood:                -125.58
No. Observations:                  99   AIC:                             257.2
Df Residuals:                      96   BIC:                             264.9
Df Model:                           2
Covariance Type:            nonrobust
==================================================================================
                     coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------
const              9.6907      0.165     58.902      0.000       9.364      10.017
nb_contextes       0.0230      0.004      5.407      0.000       0.015       0.031
ratio_fichier     -1.2607      0.531     -2.373      0.020      -2.315      -0.206
==============================================================================
Omnibus:                        2.536   Durbin-Watson:                   1.774
Prob(Omnibus):                  0.281   Jarque-Bera (JB):                1.920
Skew:                           0.174   Prob(JB):                        0.383
Kurtosis:                       2.413   Cond. No.                         197.
==============================================================================
```

4. Formulation du modèle

Le modèle final estimé s'écrit :

$$\hat{y} = 9.66 + 0.023 \cdot nb_contextes - 1.13 \cdot ratio_fichier$$

Cette équation permet d'interpréter directement l'effet marginal de chaque variable.

- Une augmentation d'un contexte consulté est associée, toutes choses égales par ailleurs, à une augmentation moyenne de la note de 0.023 point

- Une augmentation de 10 contextes correspond ainsi à une hausse moyenne d'environ 0.23 point
- Une augmentation de la proportion d'activité liée aux fichiers est associée à une diminution de la note
- Par exemple, une augmentation de 0.1 du ratio_fichier entraîne une baisse moyenne d'environ 0.113 point

L'ordonnée à l'origine (9.66) correspond à une valeur de référence théorique.

5. Interprétation statistique

Le modèle OLS final présente un coefficient de détermination de **$R^2 \approx 0.252$ (R^2 ajusté $\approx$ 0.237)**. Le modèle explique donc environ **25 % de la variance des notes**, ce qui indique une capacité explicative modérée.

Les deux variables retenues sont statistiquement significatives, *nb_contextes* a un coefficient positif et *ratio_fichier* a un coefficient négatif.

Donc, le modèle capture un signal comportemental réel, mais celui-ci reste partiel. Les variables retenues expliquent certaines tendances générales, sans permettre une prédiction fine au niveau individuel.

6. Métriques d'évaluation

Afin d'évaluer la qualité des prédictions du modèle, plusieurs métriques ont été utilisées.

a) Erreur quadratique moyenne (MSE)

La MSE (Mean Squared Error) mesure l'erreur moyenne au carré entre les valeurs réelles et les valeurs prédites :

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Elle pénalise fortement les grandes erreurs.

b) Racine de l'erreur quadratique moyenne (RMSE)

La RMSE (Root Mean Squared Error) est la racine carrée de la MSE :

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Elle s'exprime dans la même unité que la variable cible (la note), ce qui facilite son interprétation.

c) Erreur absolue moyenne (MAE)

La MAE (Mean Absolute Error) mesure l'erreur moyenne en valeur absolue :

$$MAE = \frac{1}{n}\sum_{i=1}^{n} | y_i - \hat{y}_i |$$

Contrairement à la MSE, elle est moins sensible aux valeurs extrêmes.

d) Coefficient de détermination (R^2)

Le coefficient de détermination mesure la proportion de la variance de la variable cible expliquée par le modèle :

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

Où $\bar{y}$ représente la moyenne des valeurs réelles.

Un R^2 proche de 1 indique un bon pouvoir explicatif, tandis qu'un R^2 proche de 0 indique un modèle peu performant.

7. Évaluation prédictive

Après séparation en échantillons d'entraînement et de test, les performances obtenues sont :

- MSE = 0.828
- RMSE = 0.910
- **R^2 = 0.233**

Ces résultats confirment une capacité prédictive limitée.

Le graphique des « valeurs réelles versus valeurs prédites » met en évidence une dispersion importante autour de la droite idéale ($y = x$), une tendance globale correctement capturée et une faible précision des prédictions individuelles.

Ce constat est cohérent avec la valeur du $\boldsymbol{R^2}$, indiquant que le modèle capture une tendance moyenne mais ne permet pas une prédiction fine au niveau individuel

Le modèle est capable de reproduire une tendance moyenne, mais échoue à prédire précisément les notes individuelles.

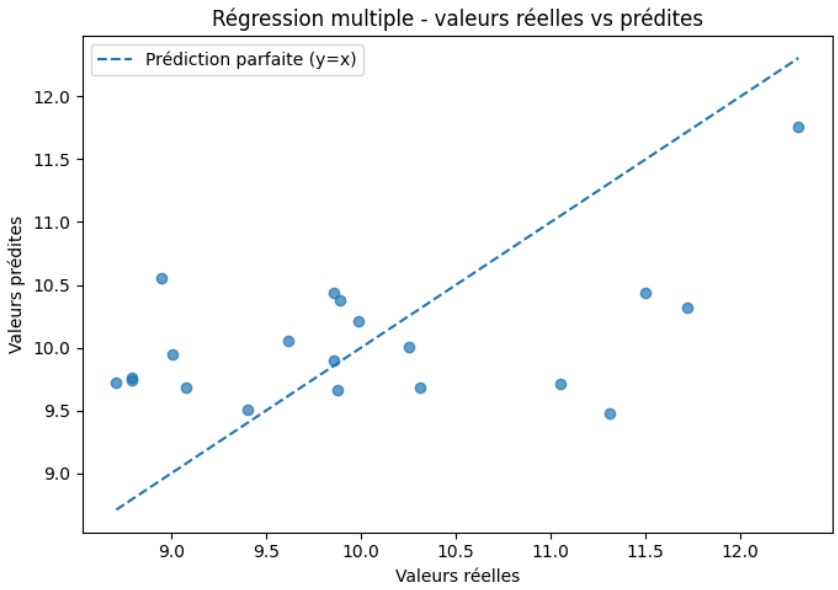

Figure 8 : Valeurs Prédites vs Valeurs Réelles

8. Multicolinéarité

Le calcul du VIF montre des valeurs proches de 1 pour les variables retenues :

- nb_contextes : VIF ≈ 1.01
- ratio_fichier : VIF ≈ 1.01

Cela indique une absence de multicolinéarité significative dans le modèle final, ce qui garantit la stabilité des coefficients estimés.

9. Limites du modèle

Plusieurs facteurs peuvent expliquer la performance modérée du modèle :

- **Faible variance de la variable cible** : les notes sont concentrées autour de 10, ce qui limite la capacité du modèle à discriminer les individus.

- **Information partielle des logs** : les données utilisées ne capturent qu'une partie du comportement étudiant (activité sur ARCHE), et ignorent d'autres facteurs importants (travail hors plateforme, niveau initial, etc.).
- **Relation non strictement linéaire** : la relation entre les variables comportementales et la note n'est probablement pas purement linéaire, ce qui limite la pertinence d'un modèle OLS.

Cette dernière limite justifie l'utilisation d'un modèle non linéaire (arbre de décision) en complément.

10. Conclusion

La régression multiple met en évidence un lien statistique entre certains comportements sur la plateforme et la performance académique. La diversité des contextes apparaît comme un facteur favorable, tandis qu'une activité centrée sur les fichiers est associée à de moins bonnes performances. Le modèle est utilisé à la fois dans une logique explicative (identification des facteurs influençant la note) et prédictive.

Cependant, sa capacité explicative et prédictive reste limitée, ce qui confirme que les traces d'activité constituent un signal pertinent mais incomplet.

VI. Modèle comparatif : arbre de décision régressif

Afin de compléter l'analyse réalisée avec la régression multiple, un modèle de type arbre de décision régressif a été construit.

L'objectif n'est pas de remplacer le modèle principal, mais d'introduire une approche capable de capturer d'éventuelles relations non linéaires entre les variables explicatives et la note.

1. Principe du modèle

L'arbre de décision segmente les observations en sous-groupes homogènes en fonction de règles de décision successives.

Chaque division repose sur un seuil appliqué à une variable explicative, permettant de réduire l'erreur de prédiction au sein de chaque groupe.

Contrairement à la régression multiple, ce modèle ne suppose pas de relation linéaire entre les variables.

2. Variables utilisées

Afin de garantir la cohérence de la comparaison, l'arbre de décision a été entraîné sur les mêmes variables que celles retenues par la sélection backward dans la régression multiple.

Dans le cas présent, les variables utilisées sont : nb_contextes et ratio_fichier

Ce choix permet d'assurer que les différences de performance observées proviennent du modèle lui-même, et non d'un changement d'espace explicatif.

3. Résultats obtenus

Les performances du modèle sont les suivantes :

- RMSE ≈ 0.870
- MAE ≈ 0.718
- $R^2 \approx 0.299$

Ces résultats sont légèrement supérieurs à ceux de la régression multiple.

4. Analyse graphique

L'analyse du graphique « valeurs réelles vs valeurs prédites » met en évidence une dispersion notable des points autour de la diagonale, similaire à celle observée pour la régression.

Cela indique que, malgré une amélioration des métriques, la qualité des prédictions reste limitée.

L'étude des résidus montre :

- une distribution globalement centrée autour de zéro
- une dispersion légèrement plus faible que pour la régression
- et un léger biais positif ($\mu \approx 0.10$)

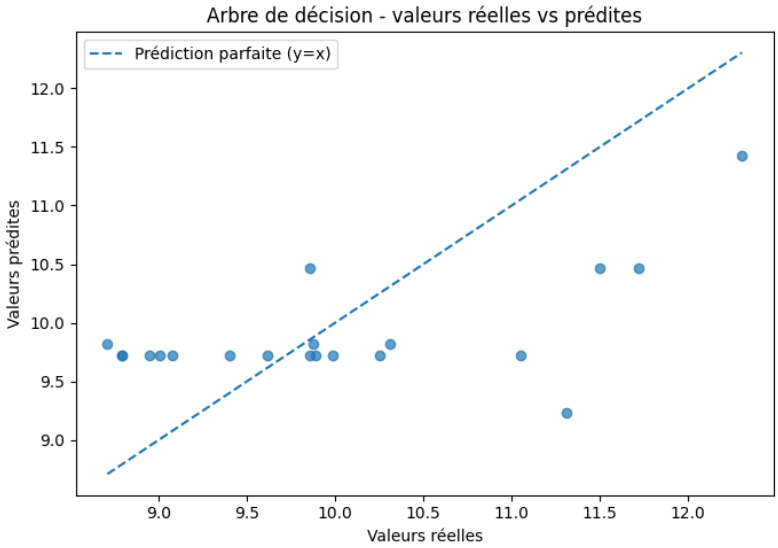

Figure 9 : Valeurs Réelles vs Valeurs Prédites AR

5. Interprétation

L'amélioration observée suggère que certaines relations entre les variables et la note ne sont pas strictement linéaires. L'arbre de décision est capable de modéliser des effets de seuil, ce qui peut expliquer sa meilleure performance.

Cependant, le gain reste modéré, ce qui indique que les limites principales proviennent des données disponibles plutôt que du choix du modèle.

6. Limites du modèle

L'arbre de décision présente plusieurs limites :

- sensibilité aux variations de données (instabilité) ;
- risque de surapprentissage si la profondeur n'est pas contrôlée ;
- interprétation locale (par règles), mais moins globale que la régression.

7. Conclusion

L'arbre de décision constitue un modèle comparatif pertinent, permettant de tester une approche non linéaire.

Il améliore légèrement la performance prédictive, mais ne résout pas les limites structurelles liées aux données.

VII. Analyse comparative des modèles

Une comparaison des modèles a été réalisée à partir des métriques classiques d'évaluation en régression : MSE, RMSE, MAE et coefficient de détermination R^2.

Les résultats obtenus sont les suivants :

Modèle	**MSE**	**RMSE**	**MAE**	**R^2**
Régression multiple	0.828	0.910	0.761	0.233
Arbre de décision régressif	0.757	0.870	0.718	0.299

1. Qualité des prédictions

L'analyse des graphiques « valeurs réelles vs valeurs prédites » met en évidence une dispersion non négligeable des observations autour de la diagonale, traduisant une précision limitée des deux modèles.

Cette dispersion est plus marquée pour les valeurs élevées de la note, ce qui suggère une difficulté à modéliser les comportements extrêmes.

2. Analyse des résidus

Les distributions de résidus sont globalement centrées autour de zéro pour les deux modèles, indiquant l'absence de biais systématique majeur. Toutefois, la régression multiple présente une dispersion plus importante des résidus ($\sigma \approx 0.91$), traduisant une variabilité élevée des erreurs et l'arbre de décision montre une dispersion légèrement plus faible ($\sigma \approx 0.86$), mais un léger décalage du résidu moyen ($\mu \approx 0.10$).

Ces éléments indiquent que, malgré une légère amélioration, les erreurs restent significatives pour les deux approches.

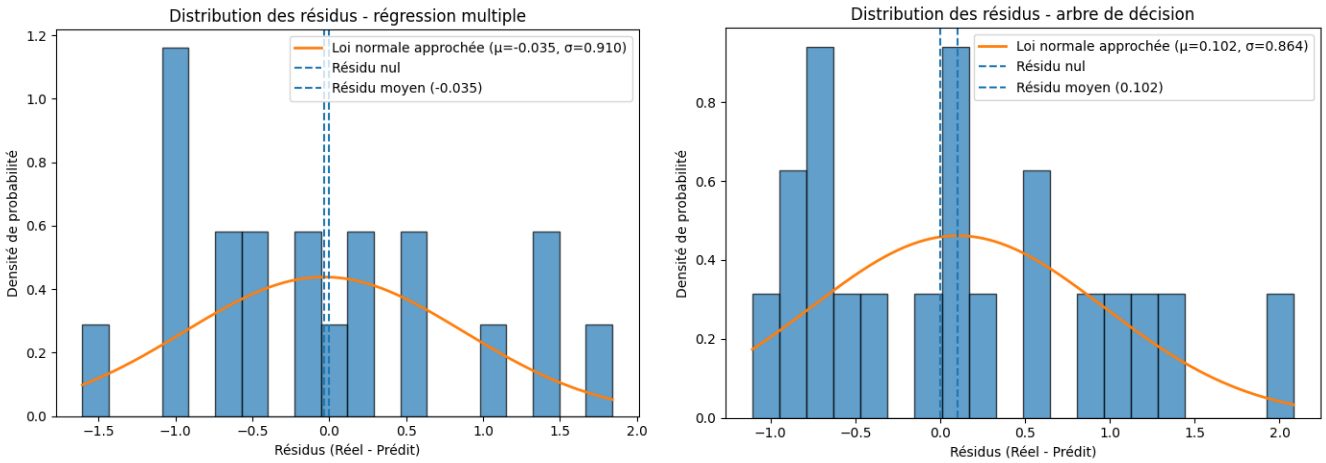

Figure 10 : Distribution des résidus

3. Capacité explicative

Les coefficients de détermination restent relativement faibles :

- $R^2 \approx 0.233$ pour la régression multiple ;
- $R^2 \approx 0.299$ pour l'arbre de décision.

Ces valeurs signifient que les variables explicatives retenues ne permettent d'expliquer qu'une part limitée de la variance de la note (environ 23 % à 30 %).

Une proportion importante de la variabilité demeure donc non expliquée par les données disponibles.

4. Comparaison des performances

L'arbre de décision présente des performances légèrement supérieures sur l'ensemble des métriques :

- RMSE plus faible, indiquant une meilleure précision globale,
- MAE plus faible, confirmant une réduction de l'erreur moyenne,
- Et R^2 plus élevé, traduisant une meilleure capacité explicative.

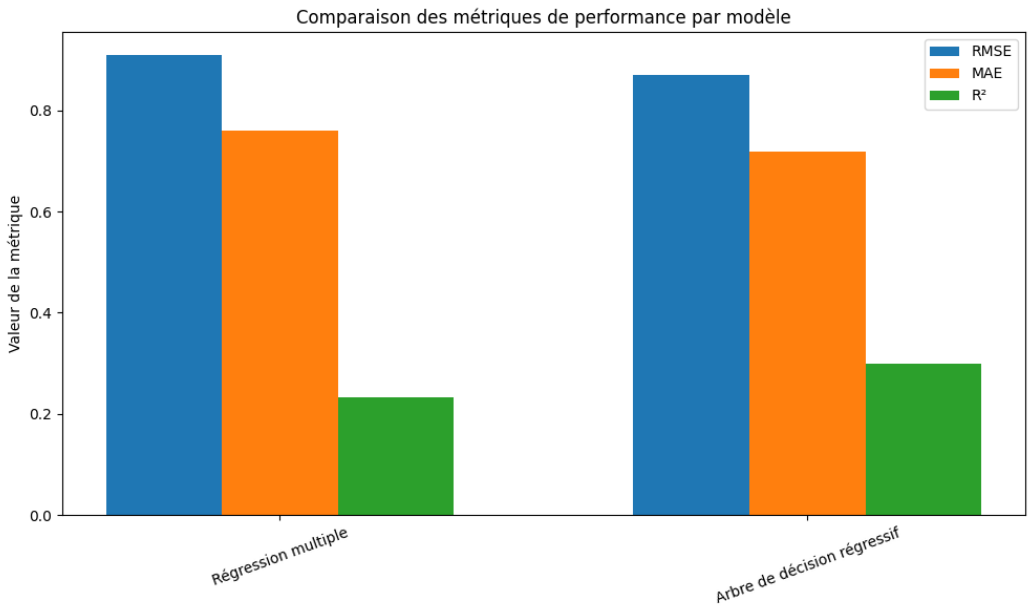

Figure 11 : Comparaison des métriques

Cependant, l'écart entre les deux modèles reste modéré, ce qui suggère une limite structurelle liée aux données plutôt qu'un véritable avantage méthodologique.

5. Interprétation

Ces résultats indiquent que la relation entre les variables issues des traces ARCHE et la note finale n'est pas strictement linéaire. L'amélioration observée avec l'arbre de décision suggère l'existence de relations non linéaires ou de seuils dans les comportements étudiants.

Cependant, les performances globales restent limitées, ce qui laisse supposer que des facteurs importants (travail hors plateforme, niveau initial, engagement personnel) ne sont pas capturés par les données.

6. Conclusion

L'arbre de décision est retenu comme modèle légèrement plus performant du point de vue prédictif. Néanmoins, la régression multiple conserve un intérêt majeur pour l'interprétation des relations entre variables.

La comparaison met ainsi en évidence une complémentarité entre les approches ainsi que les limites inhérentes aux données utilisées.

VIII. Interface de prédiction

1. Positionnement dans le projet

L'interface de prédiction constitue la couche applicative du projet. Elle intervient en aval des étapes de préparation des données, de construction des variables explicatives et de modélisation. Son rôle est de rendre les résultats exploitables en dehors de l'environnement de développement, en proposant un point d'entrée utilisateur permettant de mobiliser les modèles construits. Elle assure ainsi la transition entre une approche analytique et une utilisation concrète du modèle.

2. Objectif de l'interface

L'objectif de l'interface n'est pas de reproduire l'ensemble de la complexité du pipeline, mais de proposer une restitution simplifiée, cohérente et interprétable. Elle permet à un utilisateur de saisir un profil étudiant à partir des variables explicatives retenues, puis d'obtenir une estimation de la note associée, accompagnée d'éléments de lecture. L'interface remplit donc une double fonction : produire une prédiction et en faciliter l'interprétation.

3. Cohérence avec la modélisation

Les variables proposées dans l'interface ne sont pas choisies arbitrairement. Elles correspondent aux variables retenues à l'issue du processus de sélection dans la régression multiple. Afin de garantir cette cohérence, les champs de saisie sont générés dynamiquement à partir des variables effectivement utilisées par le modèle. Cette approche permet d'éviter toute divergence entre l'interface et la phase de modélisation. Dans la version finale du projet, les variables retenues sont le nombre de contextes consultés et le ratio d'interactions avec les fichiers, qui apparaissent comme les plus pertinentes dans l'analyse.

4. Logique de prédiction

Une fois les variables saisies, l'application applique les deux modèles développés : la régression multiple et l'arbre de décision régressif.

Contrairement à une interface figée, les champs de saisie sont générés dynamiquement, ce qui garantit une cohérence entre l'interface et le modèle effectivement entraîné.

Chaque modèle produit une estimation de la note. Plutôt que d'imposer un choix a priori, l'interface compare leurs performances globales, notamment à travers l'erreur quadratique moyenne et le coefficient de détermination.

Le modèle recommandé est alors déterminé automatiquement en fonction de ces critères. Donc, il est sélectionné en fonction des performances observées sur l'échantillon de test, notamment le RMSE et le coefficient R^2.

Cette approche permet de maintenir une cohérence entre l'interface et les résultats de l'évaluation des modèles.

5. Restitution des résultats

La restitution proposée par l'interface dépasse le simple affichage d'une valeur prédite. Elle s'organise autour de plusieurs niveaux de lecture complémentaires.

La note estimée est accompagnée d'un niveau de performance, obtenu par une catégorisation qui permet de rendre le résultat plus lisible. Un profil synthétique est également proposé, afin de qualifier le comportement de l'étudiant.

Une interprétation textuelle vient expliciter les caractéristiques du profil, tandis qu'un positionnement par rapport aux moyennes du jeu de données permet de situer l'utilisateur dans la distribution observée.

Enfin, une recommandation est formulée, dans une logique pédagogique visant à traduire le résultat en action.

6. Exemple d'interprétation d'un profil

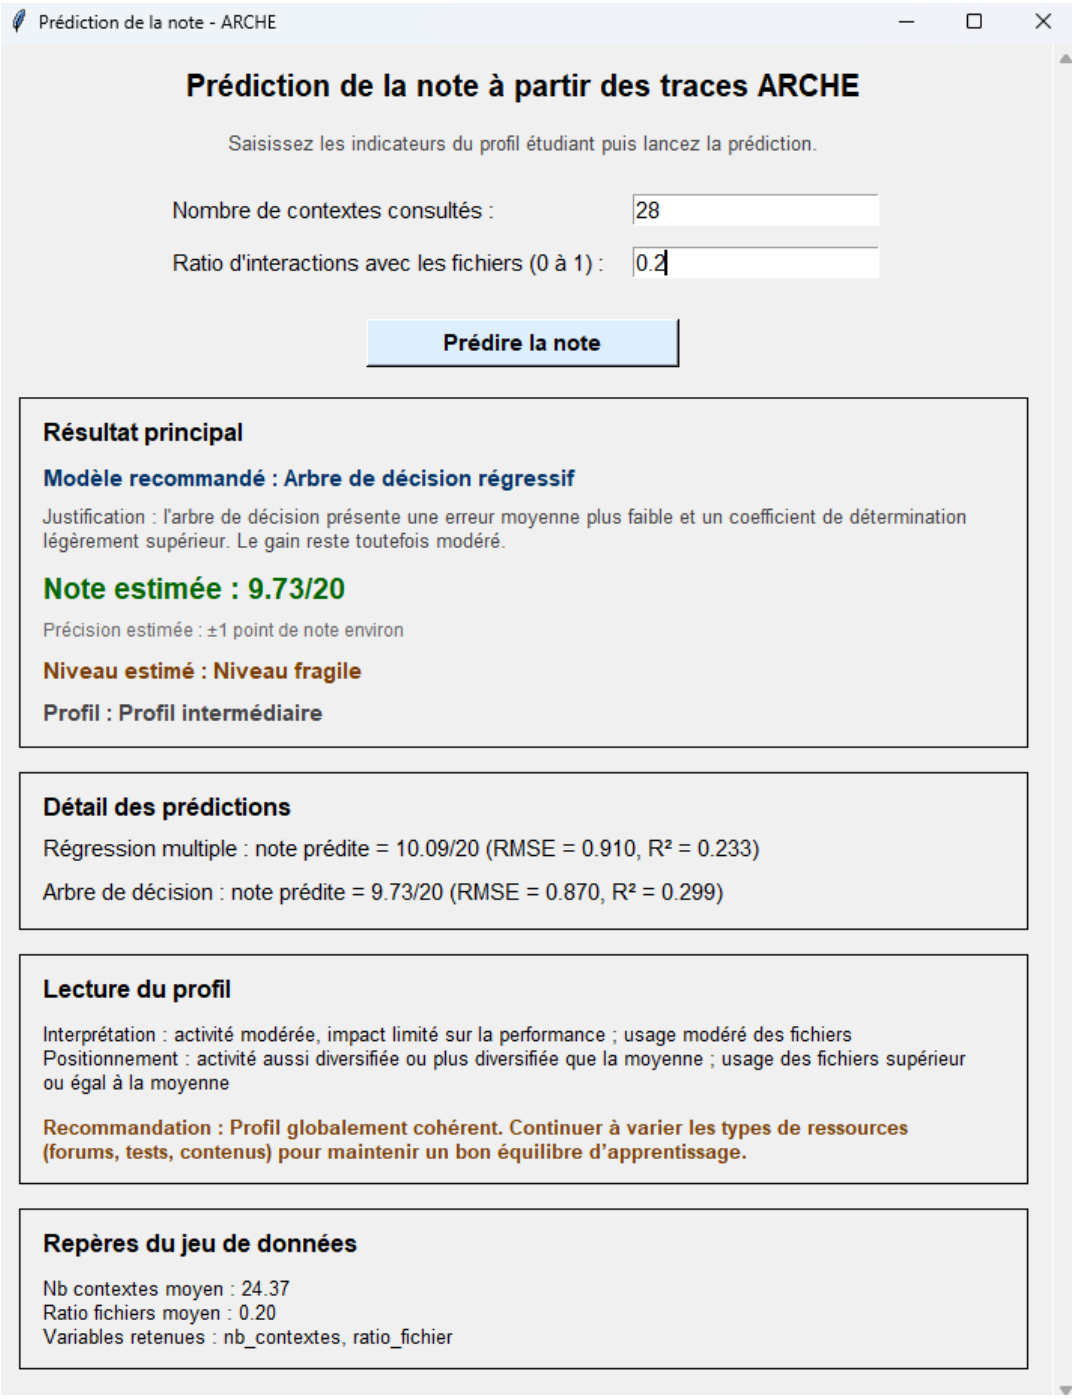

Figure 12 : Interface graphique de prédiction

La figure ci-dessus présente un exemple d'utilisation de l'interface pour un profil caractérisé par un nombre de contextes consultés égal à 28 et un ratio d'interactions avec les fichiers de 0,20.

Pour ce profil, les deux modèles produisent des estimations proches mais distinctes : la régression multiple prédit une note de 10,09 tandis que l'arbre de décision estime la note à 9,73. L'arbre de décision est retenu comme modèle recommandé, en raison de performances globales légèrement supérieures sur les données de test.

La note estimée se situe en dessous du seuil de 10, ce qui conduit à classer ce profil dans la catégorie « niveau fragile ». Cette classification ne traduit pas nécessairement un faible niveau absolu, mais indique une position relative dans la distribution des performances observées.

L'analyse du profil permet d'apporter des éléments d'interprétation. Le nombre de contextes consultés est supérieur à la moyenne du dataset, ce qui traduit une activité relativement diversifiée. En revanche, le ratio d'interactions avec les fichiers est proche de la moyenne, ce qui suggère un usage équilibré mais sans levier différenciant fort.

Ce résultat met en évidence un point important : une activité relativement diversifiée ne garantit pas nécessairement une performance élevée si elle ne s'accompagne pas d'un engagement suffisamment structuré dans les différentes ressources disponibles.

La recommandation proposée par l'interface vise ainsi à encourager une diversification qualitative des interactions, en incitant à varier davantage les types de ressources mobilisées.

Cet exemple illustre la manière dont l'interface permet de passer d'une estimation quantitative à une lecture interprétable du comportement étudiant.

7. Analyse comparative des modèles sur cet exemple

Au-delà de la restitution des résultats, cet exemple permet également d'analyser le comportement des deux modèles utilisés.

Pour le profil considéré, la régression multiple prédit une note de 10,09, tandis que l'arbre de décision propose une estimation légèrement inférieure de 9,73. L'écart entre les deux prédictions reste limité, ce qui traduit une cohérence globale des modèles, mais met néanmoins en évidence des différences de fonctionnement.

La régression multiple repose sur une relation linéaire entre les variables explicatives et la note. Elle produit ainsi une estimation continue, proportionnelle aux variations des variables. Dans ce cadre, une augmentation du nombre de contextes consultés contribue directement à une amélioration de la note prédite, indépendamment d'éventuels effets de seuil.

À l'inverse, l'arbre de décision segmente l'espace des variables en sous-groupes définis par des règles successives. La prédiction dépend alors de la position du profil dans ces segments. Il en résulte une estimation moins lisse, mais capable de capter des effets non linéaires.

L'écart observé entre les deux modèles peut ainsi s'expliquer par la présence d'un seuil implicite dans l'arbre de décision. Malgré un nombre de contextes relativement élevé, le profil peut être associé à un segment caractérisé par des performances plus faibles, notamment en raison du ratio d'interactions avec les fichiers.

Cette différence illustre un point méthodologique important : les deux modèles ne capturent pas les relations de la même manière. La régression privilégie une lecture globale et continue, tandis que l'arbre de décision introduit une logique de segmentation.

Le choix de privilégier l'arbre de décision dans cet exemple repose sur ses performances légèrement supérieures sur les données de test. Toutefois, la proximité des prédictions souligne que le gain apporté par la non-linéarité reste limité dans ce contexte.

Cet exemple met ainsi en évidence que la différence entre les modèles ne réside pas uniquement dans leur performance globale, mais également dans la manière dont ils structurent la relation entre variables explicatives et variable cible.

8. Limites

L'interface peut donner une impression de précision supérieure à celle réellement fournie par les modèles. En effet, malgré la structuration des résultats, le pouvoir explicatif des modèles reste modéré, comme en témoignent les valeurs de R^2 obtenues.

Par ailleurs, la réduction du comportement étudiant à un nombre limité de variables constitue une simplification importante, qui ne permet pas de capturer l'ensemble de la complexité des interactions présentes dans les logs.

La note prédite doit donc être interprétée comme une estimation indicative, et non comme une mesure exacte du niveau réel.

9. Intérêt pédagogique

Malgré ces limites, l'interface présente un intérêt pédagogique important. Elle permet de matérialiser le lien entre les variables comportementales et la prédiction, en rendant visible l'impact des choix de modélisation.

Elle constitue également un support pertinent pour la démonstration du projet, en offrant une représentation concrète du fonctionnement du pipeline développé.
Enfin, elle illustre le passage d'une analyse purement technique à une restitution orientée utilisateur, ce qui constitue un élément central dans une démarche de data science appliquée.

10. Conclusion de l'interface

L'interface de prédiction constitue un élément clé du projet en assurant la liaison entre les différentes étapes du pipeline et l'utilisateur final.
Elle permet de transformer une modélisation statistique en un outil exploitable, tout en conservant une dimension interprétable et pédagogique.

Conclusion générale

Ce projet avait pour objectif d'analyser les traces d'activité des étudiants sur la plateforme ARCHE afin d'explorer leur lien avec la performance académique et de proposer un modèle de prédiction de la note.
Les différentes étapes du projet ont permis de transformer des données brutes, de nature événementielle, en un ensemble structuré de variables explicatives au niveau étudiant. Le feature engineering a notamment permis de faire émerger des indicateurs pertinents tels que le nombre de contextes consultés ou la répartition des types d'activités.
La régression multiple, imposée dans le cadre du projet, met en évidence un lien statistique entre certains comportements et la note. En particulier, la diversité des ressources consultées apparaît comme un facteur favorable, tandis qu'une activité centrée sur les fichiers est associée à des performances plus faibles. Toutefois, la capacité explicative du modèle reste modérée ($R^2 \approx 0.25$), ce qui indique que les variables construites ne capturent qu'une partie du phénomène étudié.
Le modèle comparatif, basé sur un arbre de décision, améliore légèrement les performances prédictives, ce qui suggère l'existence de relations non linéaires entre les variables explicatives et la note.
Ces résultats mettent en évidence que les traces d'activité constituent un signal informatif, mais incomplet. La réussite académique dépend de nombreux facteurs non observés dans les logs, tels que le travail hors plateforme, le niveau initial ou la motivation des étudiants.

Ainsi, ce projet illustre à la fois le potentiel et les limites de l'exploitation des données comportementales dans un cadre éducatif. Il constitue une démonstration de bout en bout d'un processus de data science, depuis la préparation des données jusqu'à l'évaluation des modèles, tout en soulignant l'importance d'une interprétation prudente des résultats.